Σκοπός

Στην άσκηση αυτή θα εξοικειωθείτε με τη δημιουργία διεργασιών με χρήση των κλήσεων συστήματος fork/exec, την επικοινωνία διεργασιών μέσω pipes και named pipes, τη χρήση low-level I/0, τον χειρισμό signals και τη δημιουργία shell scripts.

Ζητούμενο 1 (βάρος: 85%)

Οι βασικές οντότητες της εργασίας είναι ο listener, ο manager, και οι workers.

Listener: Η εντολή `inotifywait` στέλνει ειδοποιήσεις για τις αλλαγές στα περιεχόμενα ενός καταλόγου του file system. Με χρήση της `inotifywait` θα κάνετε monitoring των αλλαγών στα αρχεία ενός directory. Η `inotifywait` θα εκτελεστεί (με κλήση της οικογένειας exec) μέσα σε μια δική σας διεργασία `listener`.

Manager: Αποτελεί την κεντρική οντότητα του συστήματος η οποία επικοινωνεί με τη διεργασία `listener` μέσω **pipe**. Ο listener θα ενημερώνει τον manager για κάθε νέο αρχείο που ανιχνεύει στο directory που παρακολουθεί. Δηλαδή, πριν εκτελέσετε την `inotifywait`, θα πρέπει να έχετε συνδέσει την έξοδο της διεργασίας με το pipe.

Workers: Ο manager επικοινωνεί με τους workers μέσω **named pipes**. Για κάθε όνομα αρχείου που λαμβάνει ο `manager` από τον `listener`, θα ειδοποιεί ή θα δημιουργεί (αν δεν υπάρχει) μια διεργασία `worker`, η οποία ενεργεί πάνω στο συγκεκριμένο αρχείο. Κατά την έναρξη, ο manager δημιουργεί τόσους workers όσα και τα αρχεία που ενημερώνεται ότι υπάρχουν. Ο `manager` θα πρέπει να κρατάει πληροφορία για τους διαθέσιμους workers σε μία ουρά και να δημιουργεί νέους `workers` μόνο αν δεν υπάρχει κανείς διαθέσιμος. Ο κάθε worker αναλαμβάνει να επεξεργαστεί ένα αρχείο τη φορά. Τα ονόματα των named pipes είναι στην ευχέρειά σας.

Λειτουργία

Ο manager, αν ο `worker` είναι σταματημένος, πρέπει να τον ξεκινήσει (με signal SIGCONT, επειδή οι διαθέσιμοι workers θα είναι σε κατάσταση “stopped”) και θα στείλει στον `worker` πληροφορία για το ποιο αρχείο να επεξεργαστεί.

Σκοπός του worker είναι να ανοίξει το αρχείο και να αναζητήσει urls μέσω low-level I/O. Τα αρχεία είναι αρχεία κειμένου που μπορεί να περιέχουν απλό κείμενο και URLs. Η αναζήτηση περιορίζεται στα URLs που χρησιμοποιούν το πρωτόκολλο **http**, δηλαδή της μορφής http://… . Πιο συγκεκριμένα, το κάθε URL ξεκινάει με http:// και τελειώνει με έναν κενό χαρακτήρα.

Για κάθε URL που εντοπίζεται, απαιτείται να εξαχθεί η πληροφορία για το location του, χωρίς το www. Δείτε το ακόλουθο link:

https://www.techopedia.com/definition/1352/uniform-resource-locator-url

για τα διαφορετικά μέρη ενός URL. Εμείς, όπως είπαμε, ενδιαφερόμαστε να βρούμε το

location, χωρίς το www, αν υπάρχει. Για παράδειγμα, για το URL της ιστοσελίδας του τμήματος http://www.di.uoa.gr/ ως location έχουμε το “di.uoa.gr”.

Κατά τη διάρκεια της ανάγνωσης του αρχείου, ο `worker` δημιουργεί ένα νέο αρχείο στο οποίο καταγράφει όλα τα locations που ανίχνευσε μαζί με τον αριθμό εμφάνισής τους. Π.χ. αν στο αρχείο που προστέθηκε εμφανίζονται 3 URLs με location “di.uoa.gr”, το αρχείο εξόδου του worker θα περιέχει τη γραμμή “di.uoa.gr 3” και αντίστοιχα μια γραμμή για κάθε άλλο location.

Αν το αρχείο που διάβασε ο worker έχει όνομα <*filename*>, το αρχείο που δημιουργεί έχει όνομα <*filename*>.out.

Στη συνέχεια, ο `worker` ειδοποιεί τον `manager` ότι τελείωσε την εργασία του και είναι διαθέσιμος για επόμενη εντολή. Ο worker στέλνει στον εαυτό του signal SIGSTOP έτσι ώστε να μπει σε κατάσταση “stopped” και ο `manager`, που είναι γονιός της διεργασίας `worker`, να λάβει σήμα SIGCHLD και να δει ποιο παιδί άλλαξε κατάσταση με waitpid().

Οι διεργασίες δεν τερματίζουν από μόνες τους πρέπει να τις σταματήσει ο χρήστης. Ο τερματισμός του `manager` γίνεται με Control+C (σήμα SIGINT), και πριν τερματίσει πρέπει να σκοτώνει όλες τις υπόλοιπες διεργασίες (listener και workers).

Η δομή της ιεραρχίας των διεργασιών συνοψίζεται στο Σχήμα 1.

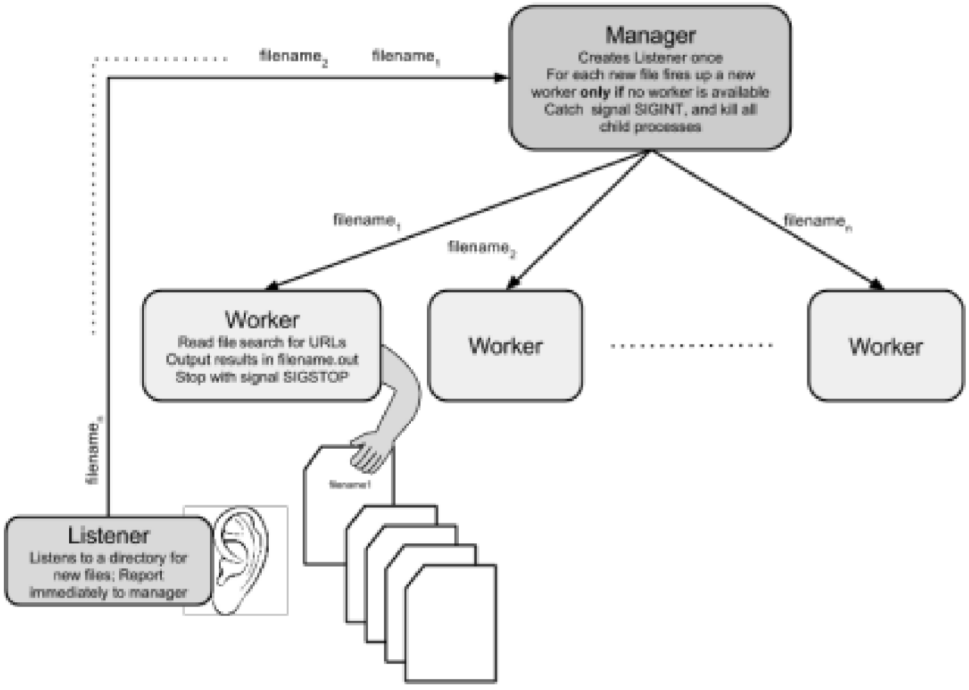

Σχήμα 1

Ζητούμενο 2 (βάρος: 15%)
Έχοντας υλοποιήσει το ζητούμενο 1, έχετε δημιουργήσει έναν αριθμό αρχείων της μορφής <*filename*>.out, τα οποία περιέχουν τα domains που βρέθηκαν μαζί με τον αριθμό εμφάνισής τους.

Σκοπός σας σε αυτό το σημείο είναι να φτιάξετε ένα shell script `finder.sh`, το οποίο θα δέχεται ως όρισμα ένα ή περισσότερα Top Level Domain (TLD) που θέλετε να αναζητήσετε στο σύνολο των .out αρχείων. Συγκεκριμένα, θα πρέπει να βρείτε το συνολικό πλήθος των εμφανίσεων του TLD στο σύνολο των αρχείων που δημιουργήσατε.

Τα αρχεία σας από το προηγούμενο ερώτημα είναι της μορφής:

```
location num_of_appearances
```

Για παράδειγμα, δίνοντας ως όρισμα το TLD “com” το αποτέλεσμα θα είναι το άθροισμα των “num_of_appearances” όπου τα locations τελειώνουν σε `com`.

Εκτέλεση Προγράμματος
Το προγραμμα σας θα ονομάζεται `sniffer`.
Η εκτέλεση του θα γίνεται **αυστηρά** ως εξής:

```
./sniffer [-p path]
```

Η προαιρετική παράμετρος “-p path” χρησιμοποιείται για να υποδείξει το path του directory που θέλουμε να γίνει το monitoring.

Στην περίπτωση που δε δίνεται αυτή η επιλογή λαμβάνεται ως default ο τρέχων κατάλογος.
Το πρόγραμμα θα πρέπει να εκτελείται απρόσκοπτα χωρίς περαιτέρω αλληλεπίδραση από τον χρήστη (όχι χρήση διαφόρων μενού κτλ),

Λεπτομέρειες Υλοποίησης

- Η διαχείριση των αρχείων πρέπει να γίνει αποκλειστικά με low-level IO.
- Η επικοινωνία μεταξύ των διεργασιών θα γίνεται αποκλειστικά με pipes, named pipes και signals οπως ακριβώς προσδιορίζεται παραπάνω.
- Η εντολή `inotifywait` είναι εγκατεστημένη στα μηχανήματα του τμήματος και μπορείτε να την εγκαταστήσετε και σε δικό σας μηχάνημα. Λεπτομέρειες για την εντολή συστήματος `inotifywait` μπορείτε να βρείτε στο manual της εντολής.
- Μπορείτε να θεωρήσετε ότι δε θα υπάρξει καμία αλλαγή στα αρχεία τα οποία εισάγονται στο directory.
- Υπόδειξη: Ο `manager` όταν πάρει σήμα από `worker` (για να ειδοποιηθεί ότι ο worker είναι ξανά διαθέσιμος) ξεμπλοκάρει από την κλήση `read` που κάνει στο κανάλι επικοινωνίας με τον `listener`. Το `read` επιστρέφει τιμή που δείχνει ότι διακόπηκε. Μπορεί τότε να ανανεώσει την πληροφορία του για διαθέσιμους `worker` και να επαναλάβει το `read`.